

Обучение с подкреплением для игры «Змейка»

Полегина А. Д.

Научный руководитель: к. ф.-м. н., доцент С. Г. Красовский

БГУ, мехмат, кафедра дифференциальных уравнений и системного анализа

Минск, 2026

Цель и задачи

Цель: разработать игру «Змейка» на Python, реализовать Q-learning для управления агентом и оценить качество обучения.

ЗАДАЧИ

- Изучить алгоритм Q-learning
- Реализовать логику игры и RL-среду
- Задать состояние, действия и награду
- Провести эксперименты

ПОЧЕМУ «ЗМЕЙКА» +
RL

Дискретная среда

Мало действий

Наглядный результат

Сравнение подходов

Подход	Плюсы	Минусы
Правила и эвристики	Простота реализации	Слабая адаптивность
Поиск траектории	Явный маршрут	Нет обучения на опыте
Табличный Q-learning	Интерпретируемость, связь с дискретной средой	Масштабируемость
DQN	Сложные состояния	Много ресурсов

Выбран табличный Q-learning

— баланс простоты и пользы для учебного проекта

Состояние агента

Вектор из 11 бинарных признаков

3

danger_straight danger_left danger_right

4

dir_up dir_down dir_left dir_right

4

food_left food_right food_up food_down

Опасность рядом

Текущее направление

Положение пищи

Компактное описание $\Rightarrow$ подходит для табличного Q-learning

Действия и награда

3 ОТНОСИТЕЛЬНЫХ ДЕЙСТВИЯ

Прямо

Влево

Вправо

Относительные действия уменьшают избыточность: одинаковый смысл при любом направлении


ФУНКЦИЯ НАГРАДЫ

Событие	Награда
Пища	+10.0
Столкновение	-10.0
Шаг	-0.1

Штраф за шаг $\Rightarrow$ агент не движется бесконечно по кругу

Архитектура программной системы

Архитектура проекта Snake RL



Алгоритм Q-learning

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

ГИПЕРПАРАМЕТРЫ


α	γ	ϵ_0	decay
0.1	0.9	1.0	0.995

ϵ -жадная стратегия:


ϵ : 1.0 $\rightarrow$ 0.05

баланс исследования и использования


Интерфейс программы



Ручная игра



Режим агента



Game over

Методика эксперимента

5
запусков

×

8
вариантов

×

100
тестовых игр


ЭПИЗОДЫ ОБУЧЕНИЯ

50, 100, 200, 300, 500, 800, 1000, 1200

МЕТРИКА

Средний score на 100 тестовых играх
(без исследования, $\varepsilon = 0$)

Результаты обучения



Рост качества игры

Эпизоды	Средний score	Лучший score
50	4.26	15.80
100	7.54	19.20
500	13.96	21.40
1200	16.23	21.60

Средний score
4.26 → **16.23**

После 800 эпизодов рост замедляется
⇒ выход на плато

Выводы

- Цель достигнута: игра реализована, агент обучен, результаты проанализированы
- Табличный Q-learning формирует эффективную стратегию без нейросетей
- 11 бинарных признаков — компромисс между простотой и информативностью
- Перспективы: влияние гиперпараметров, DQN для сложных состояний

Спасибо за внимание